

上海交通大学

SHANGHAI JIAO TONG UNIVERSITY

学士学位论文

BACHELOR'S THESIS



论文题目: 电动车送货与充电联合优化

学生姓名: 王禹铭

学生学号: 517021910455

专 业: 电气工程及其自动化

指导教师: 尚策

学院(系): 电子信息与电气工程学院

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文《电动车送货与充电联合优化》，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：王禹铭

日期：2021 年 6 月 2 日

上海交通大学

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权上海交通大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保密☐，在___年解密后适用本授权书。

本学位论文属于

不保密☒.

(请在以上方框内打“√”)

学位论文作者签名：王禹铭

指导教师签名：高策

日期：2021年6月2日

日期：21年6月2日

电动车送货与充电联合优化

摘要

现如今,电动汽车由于其较低的燃料成本,少量的温室气体排放等诸多优势,逐渐成为物流行业的主流配送工具。针对这一社会现象,本文进行了文献调研,引入了带有柔性时间窗和充电站的电动车辆路径规划问题(E-VRPTW),并对其进行分析,希望解决这一工程问题。对于该问题的算例,给定了各个客户点、充电站和配送中心的地理信息数据,并且给出了电动车辆的载重上限、客户的服务时间窗、电动车辆的电量上限。这些约束使得本文的算例更为接近现实生活中物流配送情况。本文的目标是设计一个算法,能够在满足各类约束条件的前提下,最小化该问题的车辆规划路径的费用。

在模型构建上,本文建立了混合整数规划的数学模型。在求解方法上,本文中使用的研究较为成熟的遗传算法,并在其基础上提出了一种改进的遗传算法设计,针对传统的遗传算法的部分缺陷,进行了改进和优化,使得本文的遗传算法更加适合求解含充电站和时间窗的车辆路径规划问题(E-VRPTW)。此外,本文给出了实验算例的设计思路,并采用该算例进行实验。实验结果证明了本文中所设计的遗传算法在处理该问题时,在运行时间稳定性、目标函数收敛性、路径规划结果合理性、时间窗吻合程度等多方面有较为优异的表现。本文中所提出的模型构建思路,遗传算法改进思路能够为节省电动车物流的费用,推广电动车物流的发展和实现能源电力设备的配置与能量管理起到一定的借鉴意义。

关键词: 车辆路径规划问题, 电动车, 充电站, 遗传算法, 混合整数规划, 柔性时间窗

JOINT OPTIMIZATION OF ELECTRIC VEHICLE DELIVERY AND CHARGING

ABSTRACT

Nowadays, electric vehicles have gradually become the mainstream distribution tool in the logistics industry due to their low fuel costs, a small amount of greenhouse gas emissions, and many other advantages. Aiming at this social phenomenon, this paper conducted a literature survey and introduces the electric vehicle routing planning problem with time window and charging station(E-VRPTW) and analyzes it, hoping to solve this engineering problem. For examples of this problem, given the respective customer site, the geographic information data distribution center and charging station, and gives a load limit, the customer service time window, the upper limit of the electric vehicle battery electric vehicle. These constraints make the calculation example in this paper closer to the logistics and distribution situation in real life. Goal of this paper is to design an algorithm that can cost under the premise of meeting all kinds of constraints, to minimize the problem of vehicle route planning

In terms of model construction, this paper establishes a mathematical model of mixed integer programming. In terms of the solution method, this paper proposes an improved genetic algorithm design, which is improved and optimized for some of the defects of the traditional genetic algorithm, making the genetic algorithm in this paper more suitable for solving electric vehicle routing planning problem with time window and charging station(E-VRPTW). In addition, this article gives the design idea of the experimental example and uses this example to carry out the experiment. The experimental results prove that the genetic algorithm designed in this paper has an excellent performance in the stability of running time, the convergence of the objective function, the reasonableness of the path planning results, and the degree of time window coincidence when dealing with this problem. The model construction ideas and genetic algorithm improvement ideas proposed in this paper can be used as a reference for saving the cost of electric vehicle logistics, promoting the development of electric vehicle logistics, and realizing the configuration and energy management of energy and power equipment.

Key words: vehicle routing problem, electric vehicle, charging station, genetic algorithm, mixed integer programming, soft time window

目 录

第一章 绪论	1
1.1 研究现状综述	1
1.1.1 带时间窗的车辆路径问题(VRPTW)的研究现状	1
1.1.2 电动车路径规划问题(E-VRP)的研究现状	1
1.2 本文研究内容与框架	2
1.3 本章小结	2
第二章 E-VRPTW 的问题描述与模型构建	3
2.1 带充电站和时间窗的车辆路径问题(E-VRPTW)描述	3
2.2 模型构建	3
2.2.1 假设条件	3
2.2.2 符号声明	4
2.2.3 目标函数构建	4
2.2.4 数学模型	6
2.3 本章小结	7
第三章 针对 E-VRPTW 的遗传算法设计	8
3.1 遗传算法概述	8
3.1.1 遗传算法的基本组成	8
3.1.2 遗传算法的优缺点	8
3.2 遗传算法的流程详述	9
3.2.1 编码和解码方式	9
3.2.2 初始化种群生成	9
3.2.3 适应度函数计算	10
3.2.4 选择算子操作	10
3.2.5 交叉算子操作	10
3.2.6 变异算子操作	10
3.2.7 算法终止条件	12
3.3 遗传算法流程图	12
3.4 本章小结	12
第四章 实验结果与分析	14
4.1 算例介绍	14
4.1.1 各节点的基本信息	14
4.1.2 电动车及其他配置的参数	16
4.2 实验运行环境	16
4.3 算例结果与分析	16
4.3.1 使用线性规划算法对车辆数目选择进行验证	17
4.3.2 各个节点的时间窗的吻合情况	19
4.3.3 载重约束和电量约束的满足情况	20
4.3.4 算法运行速度和迭代速度的分析	20
4.4 本章小结	23

第五章 结论-----	24
参考文献-----	26
谢辞-----	28

第一章 绪论

这些年以来,我国更是大力倡导绿色环保的概念,清洁能源持续扩容,目的在于快速构建一个清洁低碳的能源体系^[1]。党的十八大以来,我国煤清洁能源消费比重已经提高整整 6.3 个百分点,这个数据足以说明如今的发展趋势。电动汽车,特别是电池驱动的电动物流车,在降低燃料成本、减少温室气体排放方面具有潜在的长期经济和环境效益。采用电动物流车来进行物流配送,不仅可以提升物流公司的“绿色”形象的能力,更是可以让公司享受到政府税收优惠,因此近些年逐渐成为物流配送的主力工具。

1.1 研究现状综述

车辆路径规划问题(VRP)是物流配送领域的一个核心问题,通过最小化从某个仓库开始到同一地点结束的总距离来确定容量受限车辆的路线的问题。本文所研究的含充电站和时间窗的车辆路径规划问题(E-VRPTW)是对车辆路径规划问题(VRP)的一个延申^[21],下面对于带时间窗的车辆路径规划问题(VRPTW)与电动车路径规划问题(E-VRP)的研究现状进行回顾。

1.1.1 带时间窗的车辆路径规划问题 (VRPTW) 的研究现状

Nalepa J 在 2016 年提出了一种新的自适应 memetic 算法(AMA-VRPTW)来求解 VRPTW。AMA-VRPTW 根据当前的优化状态,自适应地调整其各个参数,包括群体规模、交叉算子过程中每对父染色体产生的子染色体数量和选择方案。文章中指出在执行算法之前确定合适的算法参数的问题在实践中是非常困难的,并且需要大量的计算工作来验证每个参数集,这是其他先进算法的一个重大缺陷^[2]。Zhenfeng G 在 2017 年对于具有时间窗约束的电动汽车路径问题,同时考虑了时间窗违规的驾驶成本和处罚成本,采用遗传算法求解确定了最优路径。并指出遗传算法是解决 E-VRPTW 的一种鲁棒方法^[3]。Abidi H 在 2018 年对于带有动态变化的窗口约束的车辆路径规划问题进行了研究,提出了一种具有简单启发式的遗传算法来进行求解。在所罗门的基准测试中,在操作期间,算法显示了不同的订单百分比^[4]。Marinakis Y 在 2019 年对于带时间窗的车辆路径问题,提出了一种新的粒子群算法(PSO),并采用了三种不同的自适应策略^[5]。Zulvia 在 2020 年提出了针对易腐产品的绿色车辆路径问题,目标为优化运营成本、变质成本、碳排放和客户满意度。该模型考虑了时间窗口、高峰时段和非高峰时段不同的出行时间以及工作时段,采用多目标梯度进化算法(MOGE)求解模型^[6]。

1.1.2 电动车路径规划问题 (E-VRP) 的研究现状

Jane Lin 在 2016 年提出了一种确定电动汽车最小总成本路径策略的通用方案。设定的 E-VRP 的总成本包括旅行时间成本和能量成本,考虑的是有限的电池容量和可以不受限的充电站。考虑电池的消耗不仅受到车速的影响,而且还受到车辆负载的影响,而车辆负载反过来又受到客户需求和拜访订单的影响。并通过算例证明与柴油卡车的 VRP 相比, E-VRP 具有优秀的行驶时间和距离,但电动汽车较长的充电时间意味着相当多的额外劳动力成本,并且充电站相对于客户点的分布对于路径规划策略有很大影响^[7]。Alejandro Montoya 在 2017 年引入了一种新的具有非线性充电函数的电动汽车路径规划问题(E-VRP-nl)。并通过实验结论指出对于非线性充电函数的电动汽车路径规划问题,最好的解决方案

倾向于使用多次中途充电，部分充电的策略^[8]。Daanish 在 2017 年提出了一种基于最邻近搜索的解决电动汽车节能路由问题的解决方案，并将算法应用于 VRP 数据，仿真结果证明了该算法在生成考虑充电节点的电动汽车路径问题的优化解时的准确性^[9]。Zuo X 在 2018 年通过采用混合整数线性规划技术对电动汽车充电系统进行建模，并对蓄电池的充电时间进行确定，通过计算实验验证了该模型的可行性，并与传统的路径模型进行了比较，结果表明该模型更适合实际应用，能够产生更好的调度，提高电动汽车的利用率^[10]。Erdelić T 和 Carić T 在 2019 年通过研究，提出由于电动汽车的特性，E-VRP 变体问题已经包括：电动汽车和传统汽车混合车队，部分充电策略，非线性充电，不同充电技术，电池交换技术，混合动力汽车等。因此需要发展启发式算法比如自适应大邻域搜索和混合遗传算法，来针对各种 E-VRP 的变体问题找到最优或接近最优的解决方案^[11]。Zhou Y 在 2020 年提出对于 E-VRP 未来的研究需要较为现实的约束，如交通拥堵、电网限制、充电站限制等。并且电动车作为一种新型绿色汽车除了以最小化出行距离、时间和成本作为目标，值得考虑新的更相关的目标函数。最后应该尝试开发更有效的大规模问题算法^[12]。Basso R 在 2021 年针对电动汽车局部充电路径问题提出了基于机器学习的概率能量消耗模型，该模型可以估计道路连接、路径预期能量和方差；此外还提出了结合能源预测和概率约束的部分充电的两阶段规划模型。最后通过数值实验，验证和分析了模型在现实情景的效果^[13]。

1.2 本文研究内容与框架

本文通过设立假设条件等方式将复杂的问题抽象成数学表达式，建立了带有柔性时间窗和充电站的电动车物流规划问题(E-VRPTW)的模型，将最小化整个路径规划的总费用作为优化目标，并通过改进的遗传算法进行求解，证明了本文设计的算法的有效性和合理性。本文中所提出的模型构建思路，遗传算法改进思路能够为节省电动车物流的费用，推广电动车物流的发展和实现能源电力设备的配置与能量管理起到一定的借鉴意义。

本文的论文框架如下所示：第一章是绪论部分，阐述了正对电动车物流规划问题的研究现状，并给出了本文的研究内容和方法。第二章是对于含充电站和时间窗的车辆路径规划问题(E-VRPTW)的问题描述与模型构建。第三章是对于含充电站和时间窗的车辆路径规划问题(E-VRPTW)的遗传算法设计。第四章是展示实验结果并进行分析。第五章则是给出本文的结论。总结了本文的所作出的工作内容与最终的研究结论，并给出了模型和算法中本的一些缺陷和改进方式。

1.3 本章小结

针对国内外对于车辆路径规划问题的研究进行了介绍和分析，给出了本文的研究内容框架和方法选择，介绍了本文的论文框架。

第二章 E-VRPTW 的问题描述与模型构建

2.1 带充电站和时间窗的车辆路径问题(E-VRPTW) 描述

含充电站和时间窗的车辆路径规划问题(E-VRPTW)可以认为是常规的车辆路径规划问题(VRP)的拓展, 需要额外考虑充电站所带来的行驶路程扩展、充电费用计算以及客户规定的时间窗所带来的时间窗惩罚。通过参考文献, 常见的 E-VRPTW 考虑因素为配送中心, 客户, 充电站, 电动车^[17]。下面对这些考虑因素进行说明:

(1) 配送中心

配送中心在含充电站和时间窗的电动车路径规划问题中担任中枢神经的作用, 负责调度安排整个配送任务的物流路径规划。配送中心既是每辆电动车的配送起点, 也是每辆电动车的配送终点。每辆从物流中心出发的电动物流车都是满电量, 并且可载的重量为载重上限。配送中心需要做到的是通过调度安排, 最小化整个物流配送的总成本, 与此同时尽量符合顾客的时间窗要求, 使得顾客有较高的满意度。

(2) 客户

在含充电站和时间窗的电动车路径规划问题中, 客户通常是指需要进行货物运送的商家, 比如超市等, 它们需要配送中心来抽调车辆进行物流配送服务。通常每个客户有着独立的服务时间窗, 地理位置信息, 搬运货物时间和货运量需求。不同于常见的车辆路径规划问题中客户不具有时间窗, 或者是时间窗为非柔性时间窗, 作为时间约束而存在。本文考虑的时间窗是柔性时间窗, 也就是说如果电动车在客户期待的时间窗外到达, 也是可以接受的规划, 但是需要支付客户一定数额的罚金, 罚金数目和违背时间窗的长度有关。这也符合我们的实际日常生活中的物流配送情况, 通常很难做到完全的准时到达, 当有一定金额赔偿时, 适当的不准时也通常是可以接受的。

(3) 电动车

不同于常规的车辆路径规划问题采用的是燃油车, 本文中采用的是更加节能环保的电动车, 这也符合当今社会低碳环保的改变趋势。本文中的所有电动车辆均采用相同的配置, 并根据问题规模对续航里程等方面进行等比例调整。此外, 电动车的采用也引入了充电站的考虑, 这虽然使得整体物流配送的里程得到提升, 但同时也使得考虑因素增多, 需要在传统的优化里程的基础上考虑充电策略。

(4) 充电站

由于电动车的引入, 充电站也将会作为一个考虑因素被引进。充电站起到的作用是接纳电动车, 并为其充电, 以达到延长电动车的总行驶里程和使得更多客户可以被服务的目的。电动车在充电站的充电时间恒定, 充电费用与该电动车的充电量成正比

2.2 模型构建

2.2.1 假设条件

对于含充电站和时间窗的电动车路径规划问题, 为了简化问题的复杂性, 便于将这个问题抽象成数学模型。根据 Moghaddam 提出的对于常见车辆路径规划问题的假设条件^[18], 并且结合电动车和充电站的特性, 本文中定义如下假设条件:

(1) 电动车从配送中心出发或者抵达充电站后为满电量状态;

- (2) 电动车的电池容量相同；
- (3) 电动车的耗电量和行驶距离成正比；
- (4) 电动车的充电时间和所需电量成正比；
- (5) 电动车的运输成本和行驶距离成正比；
- (6) 电动车行驶速率恒定；
- (7) 电动车不能从配送中心直接前往充电站；
- (8) 充电站充电时间固定；
- (9) 进入非充电站的节点，电动车前后电量不发生变化；
- (10) 每个客户只会被服务一次；
- (11) 每个节点的位置，需求量，时间窗在整个过程中不会发生变化；

2.2.2 符号声明

对于后续的目标函数构建和数学模型，本文中定义如下符号，具体声明参考表 2-1：

表 2-1 符号声明

符号	定义
$\{0\}$	配送中心
C	客户集合, $C = \{1, 2, \dots, c\}$
S	充电站集合, $S = \{c+1, c+2, \dots, c+s\}$
A	网格节点集合, $A = C \cup S \cup \{0\} = \{0, 1, 2, \dots, c+s\}$
K	电动车集合, $K = \{1, 2, \dots, k\}$
d_{ij}	节点 i 到节点 j 的行驶距离, $i, j \in A$
t_{ij}	节点 i 到节点 j 的行驶时间, $i, j \in A$
N_i	节点 i 的货运需求量
α	时间窗早到惩罚系数
β	时间窗迟到惩罚系数
H	电动车的耗电系数
N_{max}	电动车的载重上限
Q_1	电动车的单位距离运输成本
Q_2	电动车的单位电量充电成本
v	电动车的行驶速度
V_{max}	电动车的最大电量
dis	电动车的行驶里程上限
t_{il}	节点 i 的时间窗上限, 即最晚时间
t_{ie}	节点 i 的时间窗下限, 即最早时间
t_{is}	节点 i 的服务时间
V_{ki}	电动车 k 到达节点 i 的当前电量
D_{ki}	电动车 k 到达节点 i 的当前行驶里程
T_{ki}	电动车 k 到达节点 i 的当前时间
L_{ki}	电动车 k 到达节点 i 的当前载重量

此外，定义决策变量 X_{ijk} 来代表电动车 k 是否从节点 i 开往节点 j ，如公式 2-1 所示：

$$X_{ijk} = \begin{cases} 1, & \text{电动车 } k \text{ 从节点 } i \text{ 行驶到节点 } j \\ 0, & \text{else} \end{cases} \quad i, j \in A, k \in K \quad (2-1)$$

2.2.3 目标函数构建

路径规划的目标是使得整个电动车物流路径规划的总成本最小。其中包括运输成本，充电成本，时间惩罚成本，载重超量惩罚，电量耗尽惩罚^[17]。下面对这些成本和惩罚进行定义。

(1) 配送过程的运输成本 Z_t ：对于车辆路径规划问题，最为常见的优化目标就是最小化总体的行驶距离。在模型中，我们设定运输成本和行驶距离呈线性关系。其中 Q_1 代表单位距离的配送成本， d_{ij} 代表节点 i 到节点 j 的行驶距离， X_{ijk} 作为决策变量，如果车辆 k 从节点 i 来到节点 j 为 1，反之为 0。运输成本 Z_t 的表达式如公式 2-2 中所示：

$$Z_t = Q_1 \sum_{i \in A} \sum_{\substack{j \in A \\ j \neq i}} \sum_{k \in K} d_{ij} X_{ijk} \quad (2-2)$$

(2) 电动车在充电站的充电成本 Z_c ：充电成本主要来源于电动车到达充电站进行充电。在模型中，我们设定充电成本和充电量呈线性关系。其中 Q_2 电动车的单位电量充电成本， V_{\max} 为电动车的电量上限， V_{ki} 代表电动车 k 在节点 i 处的电量。充电成本 Z_c 的表达式如公式 2-3 中所示：

$$Z_c = Q_2 \sum_{\substack{i \in A \\ i \neq \{0\}}} \sum_{\substack{j \in S \\ i \neq j}} \sum_{k \in K} (V_{\max} - V_{ki}) X_{ijk} \quad (2-3)$$

(3) 时间惩罚成本 Z_p ：时间惩罚成本主要来源于电动车的抵达时间与客户点的期待柔性时间窗的不吻合。每个客户点都拥有独立的时间窗，并且在整个配送过程中不会发生变化，如果电动车在客户期待的时间窗内到达，则不需支付惩罚成本， $Z_p = 0$ 。如果在客户期待的时间窗外到达，需要根据早到惩罚系数 α ，迟到惩罚系数 β 来支付相应的惩罚金额。时间惩罚成本 Z_p 的表达式如公式 2-4 中所示：

$$Z_p = \sum_{k \in K} \sum_{i \in C} \alpha * \max((T_{ki} - t_{ni}), 0) + \beta * \max((T_{ki} - t_{ie}), 0) \quad (2-4)$$

(4) 载重超量惩罚 Z_{overload} ：载重超量惩罚的设定是出于防止出现路径规划中当前车辆载重 L_{ki} 超过载重上限 N_{\max} 这样不合理的结果。其中 Huge 是个设定的极大的数字，设定的取值是远大于车辆路径规划的总费用。如果当前电动车载重 L_{ki} 超过载重上限 N_{\max} ， Z_{overload} 的取值会变成 N_{\max} ，总成本会变得及其巨大，这样会导致这个路径规划在算法中优先度降低，会被舍弃。载重超量惩罚 Z_{overload} 的表达式如公式 2-5 中所示：

$$\begin{aligned} Z_{\text{overload}} &= \begin{cases} 0, L_{ki} \leq N_{\max} \\ \text{Huge}, L_{ki} > N_{\max} \end{cases}, \forall k \in K, i \in A \\ &= \sum_{i \in A} \sum_{k \in K} \text{Huge} * \max((L_{ki} - N_{\max}), 0) \end{aligned} \quad (2-5)$$

(5) 电量耗尽惩罚 $Z_{\text{overtrans}}$ ：电量耗尽惩罚得设定是出于防止出现路径规划中当前车辆行驶里程 D_{ki} 超过行驶里程上限 dis 这样不合理的结果。其中 Huge 是个设定的极大的数字，定的取值是远大于车辆路径规划的总费用。如果当前电动车行驶里程 D_{ki} 超过里程上限 dis， $Z_{\text{overtrans}}$ 的取值会变成 Huge，变得及其巨大，这样会导致这个路径规划在算法中优先度降低，会被舍弃。电量耗尽惩罚 $Z_{\text{overtrans}}$ 的表达式如公式 2-6 中所示：

$$\begin{aligned}
 Z_{overtrans} &= \begin{cases} 0, D_{ki} \leq dis \\ Huge, D_{ki} > dis \end{cases}, \forall k \in K, i \in A \\
 &= \sum_{i \in A} \sum_{k \in K} Huge * \max((D_{ki} - dis), 0)
 \end{aligned} \tag{2-6}$$

综合之前所有考虑的因素，基本假设与符号说明，我们的目标是最小化整个物流过程的总体费用 Z ，即求解 $\min(Z)$ 。其中总体费用 Z 的表达式如公式 2-7 中所示：

$$\begin{aligned}
 Z &= Z_p + Z_t + Z_c + Z_{overload} + Z_{overtrans} \\
 &= Q_1 \sum_{i \in A} \sum_{j \in A} \sum_{k \in K} d_{ij} X_{ijk} + Q_2 \sum_{i \in A} \sum_{j \in S} \sum_{k \in K} (V_{\max} - V_{ki}) X_{ijk} \\
 &\quad + \sum_{k \in K} \sum_{i \in C} \alpha * \max((T_{ki} - t_{ni}), 0) + \beta * \max((T_{ki} - t_{ie}), 0) \\
 &\quad + \sum_{i \in A} \sum_{k \in K} Huge * \max((L_{ki} - N_{\max}), 0) \\
 &\quad + \sum_{i \in A} \sum_{k \in K} Huge * \max((D_{ki} - dis), 0)
 \end{aligned} \tag{2-7}$$

2.2.4 数学模型

根据之前的目标函数确立、符号说明与假设条件，可以得到如下数学模型。分别包含模型的目标函数，变量的等式关系和模型的约束条件。具体如下所示：

$$\sum_{j \in A} X_{0jk} = 1, \forall k \in K \tag{2-8}$$

$$\sum_{i \in A} X_{i0k} = 1, \forall k \in K \tag{2-9}$$

$$\sum_{i \in A} X_{imk} = \sum_{j \in A} X_{mjk}, \forall k \in K, m \in C \cup S \tag{2-10}$$

$$\sum_{i \in A} \sum_{k \in A} X_{ijk} = 1, \forall j \in C \tag{2-11}$$

$$X_{0jk} = 0, \forall j \in S, k \in K \tag{2-12}$$

$$L_{ki} \leq N_{\max}, \forall i \in A, k \in K \tag{2-13}$$

$$V_{ki} \geq 0, \forall k \in K, i \in A \tag{2-14}$$

$$dis = V_{\max} * H \tag{2-15}$$

$$V_{kj} = \sum_{i \in A} X_{ijk} * (V_{ki} + H * d_{ij}), \forall j \in A, k \in K \tag{2-16}$$

$$D_{kj} = \sum_{i \in A} X_{ijk} * \left(\frac{V_{ki}}{H} + d_{ij} \right), \forall j \in A, k \in K \tag{2-17}$$

$$T_{kj} = \sum_{i \in A} X_{ijk} * (T_{ki} + t_{is} + t_{ij}), \forall j \in A, k \in K \tag{2-18}$$

$$L_{kj} = \sum_{\substack{i \in A \\ i \neq j}} X_{ijk} * N_i, \forall j \in A, k \in K \quad (2-19)$$

$$\min(Z) = \min(Z_p + Z_t + Z_c + Z_{\text{overload}} + Z_{\text{overtrans}}) \quad (2-20)$$

约束 2-8 表示所有电动车从配送中心出发；

约束 2-9 表示所有电动车最终回到配送中心；

约束 2-10 表示电动车的流量守恒，车辆 k 进入除货运中心外任意点 m ，之后会从 m 离开。

约束 2-11 表示任意客户 j 只会被服务一次；

约束 2-12 表示电动车不能把充电站作为离开货运中心的第一个目的地；

约束 2-13 表示电动车在任意节点的载重量不能超过载重上限；

约束 2-14 表示电动车在任意节点的剩余电量都大于 0；

等式 2-15 表示电动车的行驶里程上限和电动车的最大电量的上限的关系；

等式 2-16 表示电动车 k 到达节点 i 的当前电量；

等式 2-17 表示电动车 k 到达节点 i 的当前行驶里程；

等式 2-18 表示电动车 k 到达节点 i 的当前时间；

等式 2-19 表示电动车 k 到达节点 i 的当前载重量；

公式 2-20 代表目标函数，即最小化整个物流流程的总费用；

这些约束条件和等式定义是对于模型的完整性是至关重要的，虽然有一些约束会看起来比较理所应当，比如约束 2-10，车辆从哪个节点进入就从哪个节点离开在现实生活中是一件很显然的事情，但是在实际使用算法解决问题时，对于一些算法，如果遗漏了这样看似显然的约束，会出现问题。比如遗传算法解决这个模型，本文中的路径规划方案所采用的数据结构是 list 的形式，也就是前一个点和后一个点被整数化地连在一起。由于其数据结构的特征，自然就满足约束 2-10 中流量守恒的问题。但是当用线性规划来进行解决时，使用解法器时并没有设计好的数据结构的存在。因此，如果不能完整地给出这些约束条件，结果会出现一些漏洞。比如缺少了约束 2-10，线性规划结果就会变成多个线段离散分布的情况，显然不是一个合理的路径规划。

2.3 本章小结

本章对于含充电站和时间窗的车辆路径规划问题(E-VRPTW)的四个关键因素：配送中心，客户，电动车和充电站进行了定义。之后给出了模型的假设条件，来简化问题的复杂性，便于将这个问题抽象成数学模型。明确了目标函数为最小化车辆路径规划的总费用。总费用构成包含配送过程的运输成本，电动车在充电站的充电成本，时间惩罚成本，载重超量惩罚和电量耗尽惩罚。最后，给出了模型的目标函数，变量的等式关系和模型的约束条件的数学表达式。

第三章 针对 E-VRPTW 的遗传算法设计

3.1 遗传算法概述

3.1.1 遗传算法的基本组成

遗传算法 (Genetic Algorithms) 是一种随机搜索算法, 符合自然界物种遗传中的优胜劣汰的准则。遗传算法的本质是根据将所求问题的解决方案映射为生物种群, 种群中每一个染色体代表一个不同的解决方案, 算法中每个染色体的适应度大小代表解决方案的优秀程度, 旨在针对该问题找到一个优秀的甚至最优的解决方案^[20]。具体包含以下流程:

(1) 选择合适的编码方式对染色体进行编码。合适的编码方式是遗传算法设计成功与否的先决条件, 合适的编码方式将会降低问题复杂程度, 加快算法的迭代速率。

(2) 选择合适的种群规模并且初始化种群。种群规模必须适当, 如果种群的规模过小, 将导致算法迭代由于局部最优的情况而停滞不前; 如果种群的规模过大, 将导致算法耗时较长。

(3) 计算染色体的适应度函数值, 并将其作为一条染色体优秀程度的参考依据。适应度函数的值越大, 被选择的几率越大。适应度函数的构成与参数设计, 将会直接影响算法输出的结果。

(4) 对于优秀的染色体进行选择, 并通过交叉、变异等方法创建一个新种群, 并替换旧种群。其中选择算子操作体现了物种遗传中的优胜劣汰, 如果染色体拥有更高的适应度, 则更有可能被留下来。交叉操作体现了自然界中物种繁殖交配的规律, 子代将继承父代的优秀基因片段。而变异算子操作则体现了物种进化时, 基因发生了突变的现象, 增加种群的多样性。

(5) 不断重复第三步和第四步, 如果达到设定的终止条件, 则输出最优解。

(6) 对最优结果进行解码, 得到问题的解。

上述步骤可以由下表 3-1 中的伪代码来进行表示:

表3-1 遗传算法伪代码

步骤	伪代码
1	Encode the chromosome
2	Generate initial population
3	While $i < \text{max number of generations}$ do
4	Calculate fitness value(fit)
5	Select the current best for the next generation (elitism)
6	Crossover with a crossover probability
7	Mutate with a mutation probability
8	$i = i + 1$
9	end
10	Decode the result

3.1.2 遗传算法的优缺点

遗传算法作为一种随机搜索算法, 通过模仿自然界的优胜劣汰的机理来寻找最优解。它的优点包括:

- (1) 快速随机的搜索能力。
- (2) 具有较好的可扩展性。

(3) 鲁棒性较好^[19]。

但同时遗传算法也有一些缺点：

(1) 遗传算法需要构建很多功能和数据结构，编程有一定难度。

(2) 遗传算法的参数选择非常重要。比如对于交叉概率和变异概率的取值往往非常重要，这些参数的选择会严重影响最终结果，可能会破坏原本的优良染色体^[14]。但是目前这些参数的选择大部分是依靠经验来根据问题规模进行选择。

(3) 算法对初始种群的优秀程度有一定的依赖性，一个优秀的初始种群能让算法在相同迭代次数下得到一个更优秀的最终结果。

针对遗传算法的这些优缺点，本文进行了算法改进，来减少这些缺点对实验结果的影响。在本文的算法设计中，首先是采用载重约束作为判断条件，来提高初始化的种群的优秀程度。并且针对变异概率和交叉概率对于优良染色体的破坏问题，设计一个保留比例来确保优良染色体的存活。对于交叉操作，只会用优良染色体来作为交叉操作前的父代染色体，因此得到的子代染色体都部分保存了优良染色体的优秀基因片段，且得到这些子代染色体只会替换原本种群中非优良染色体的其中一部分，不会威胁到优秀的父代染色体的存活。对于变异操作，只会对非优良染色体进行变异操作。

3.2 遗传算法的流程详述

遗传算法主要通过染色体编码和解码、初始化种群生成、适应度函数设计、选择算子、交叉算子、变异算子这些步骤来得到迭代次数范围内的最优解。接下来将对于本文的 E-VRPTW 所采用的遗传算法的每个流程进行详细阐述。

3.2.1 编码和解码方式

确定编码方式是遗传算法设计中的第一步，常见的编码方式包含二进制编码，整数编码，符号编码等方式^[15]。本文中采用的编码方式是整数编码，染色体中包含配送中心，客户和充电站这三类信息。在后续实验的算例中，0 代表配送中心，1~25 代表客户，26, 27 代表充电站。下面通过过一个例子来说明：

比如对于一个包含 3 辆电动车，9 个客户点和 1 个物流中心的路径规划如下：

(1) 车辆 1 的路径规划：从物流中心出发，依次经过客户 1、顾客 2、顾客 3、顾客 4，最终回到充电站。

(2) 车辆 2 的路径规划：从物流中心出发，依次经过客户 5、顾客 6，最终回到充电站。

(3) 车辆 3 的路径规划：从物流中心出发，依次经过客户 7、顾客 8、顾客 9、最终回到充电站。

则这个路径规划的染色体编码为[0 1 2 3 4 0 5 6 0 7 8 9 0]。其中[0 1 2 3 4 0]片段代表车辆 1 的路径规划，[0 5 6 0]片段代表车辆 2 的路径规划，[0 7 8 9 0]片段代表车辆 3 的路径规划。

解码则是编码的逆运算，根据上述的染色体编码，我们也可以逆向得出之前的路径规划结果。

3.2.2 初始化种群生成

初始种群对于遗传算法的性能起着至关重要的作用，一个优秀的初始种群可以让遗传算法用更少的迭代次数达到最优解。本文采取的初始化种群的过程包含如下步骤：

第一步，是根据问题规模，确定种群规模大小。比如，选择种群大小为 M ，就是确定将初始化 M 个路径规划方案，并用整数编码的方式来存储。

第二步，是将所有的客户，充电站随机排列在配送中心后方。首先，对于每一个染色体序列的首位和末尾插入 0，代表一个闭环，即电动物流车从货运中心出发，并且最终回到货运中心。比如我们选择 3 辆电动车来完成配送任务，将会在序列中将增加 2 个 0 的位置，形成 3 个从 0 到 0 的子序列闭环，即 3 个车辆的路径规划。

第三步，是根据每个客户的货运量 N_i 进行计算，如果路径上累计货运量超过电动车设定的载重上限 N_{max} 如公式 3-1 中所示：

$$\sum_{i=a}^b N_i > N_{max} \quad (3-1)$$

则在染色体序列中 b 的前面的位置插入 0，代表该电动车在这段配送过程最多服务从顾客 a 到 b 前面这个顾客点，并最终回到货运中心。

其中，需要声明的是电动车数量的选择会满足的前提是没有一辆电动车超过其载重上限，也不存在多调用车辆的情况。假设每个客户点的货运需求为 N_i ，共有 n 个客户，调用的电动车的数量为 x ，每辆电动车的载重上限为 N_{max} ，则满足公式 3-2:

$$x * N_{max} \leq \sum_{i=1}^n N_i < (x+1) * N_{max} \quad (3-2)$$

第四步是重复第三步，并判断当前插入 0 的个数是否达到预设值，如果达到则停止循环，输出染色体。

重复上述步骤 M 次，直到形成具有 M 个染色体的初始化种群。

3.2.3 适应度函数计算

适应度函数用于计算群体中每个染色体的适应度值 fit ，用于衡量每个染色体的优秀程度。在这篇文章中，我们选择适应度函数为总费用 Z 的倒数，如公式 3-3 中所示：

$$fit(i) = \frac{1}{Z(i)} \quad (3-3)$$

遗传算法的优化目标是最大化适应度函数的值，也就是最小化配送的总费用。适应度函数的值越大，意味着该染色体越优秀，总费用越小，越有可能被选择到下一代。

3.2.4 选择算子操作

选择算子是从就群体中选择优良染色体组成新的种群，得到下一代种群，染色体的选择概率与适应度相关，染色体适应度值越高，被选中的概率越大。遗传算法选择操作有轮盘赌法、锦标赛发等多种方法。这样的操作符合自然界中物种优胜劣汰的准则。本文中采用轮盘赌法，具体步骤如下：

第一步，是计算每个染色体的适应度值。

第二步，是累加整个种群中每个染色体的适应度值，得到群体的适应度之和。

第三步，是用每个染色体的适应度值除群体的适应度之和，得到每个染色体的选择概率，种群数目是 $sizepop$ 。如公式 3-4 所示

$$P(i) = \frac{fit(i)}{\sum_{i=1}^{sizepop} fit(i)} \quad (3-4)$$

第四步，是根据需求选定一个(0,1)之间的实数 a 作为选择比例，并将之前的种群中的

染色体按照选择概率排序，如果大于实数 a ，则会被选择，最为优秀的染色体进行复制保存。

使用轮盘赌法，方法简单且效果优良，可以提高算法的运行效率。

3.2.5 交叉算子操作

交叉算子是指对于被选择的父染色体之间交换部分遗传特征，这样的作法不仅可以保留原来的种群中优秀的个体的特征，而且可以使得种群保持多样性，这就像自然界中物种之间进行交配得到新的后代。算法设计中，两个父染色体之间的是否进行交叉操作是依据生成的随机数和交叉概率 P_c 大小来判断的。为了提高遗传算法的进化效率，在本文的遗传算法中经常使用部分匹配交叉。具体的流程可以参考下面的例子。

比如当生成的随机数恰好大于交叉概率 P_c ，从先前选择操作中得到的优秀染色体进行选择两条染色体来进行交叉操作。假设选取的父染色体 A 的路径规划为[0 1 2 3 0 4 5 0 6 7 0]，父染色体 B 的路径规划为[0 2 4 0 3 5 1 0 7 6 0]。

第一步，对于两个父染色体，他们分别包含三段子路径，我们需要选择子路径来作为交叉区域。假设对于父染色体 A，选择[0 1 2 3 0]这段子路径作为交叉区域，对于父染色体 B，选择[0 2 4 0]作为交叉区域。

第二步，将交叉区域前置到对方染色体中，并去除复制的原始序列中的节点 0，得到染色体 A_1 为[0 2 4 0 1 2 3 4 5 6 7]，染色体 B_1 为[0 1 2 3 0 2 4 3 5 1 7 6]。

第三步，删除复制的原始序列中和交叉区域重复的节点，得到子代 A_2 为[0 2 4 0 1 3 5 6 7]，B_2 为[0 1 2 3 0 4 5 7 6]。

第四步，末尾补零，得到子代 A_2 为[0 2 4 0 1 3 5 6 7 0]，B_2 为[0 1 2 3 0 4 5 7 6 0]。

第五步，根据电动车数目，也就是子路径数目，在子代 A_2 和子代 B_2 的非交叉区域进行插 0 操作，保留插 0 后适应度函数值最大的染色体。当前假设下，我们还需要分别再插入一个 0 到两个染色体中，假设通过循环得到染色体适应度函数值最大的结果分别为 A_3[0 2 4 0 1 3 5 0 6 7 0]，B_3[0 1 2 3 0 4 5 0 7 6 0]。他们作为最终的对于父代染色体 A 和父代染色体 B 的交叉算子操作结果，进行保留。

第六步，在对于所有的优秀染色体进行上述的交叉算子操作后，还需要进行合并算子操作。对于选择前的种群，按照适应度大小进行排序，将适应度值小的染色体用刚才优秀染色体 A 和 B 通过交叉后得到的新染色体 A_3 和 B_3 进行替代，这样的做法既保留了优秀染色体，也引入了优秀的子代染色体来替换适应度差的父代染色体。

3.2.6 变异算子操作

变异算子的主要目的是保持种群多样性，体现了自然界中物种进化过程中基因发生突变的现象，但是变异的概率较低，且有可能破坏之前优秀的染色体。因此，本文中对交叉后的子代进行变异操作，其中适应度值前 30%作为优秀染色体进行保护，其余的染色体进行变异操作，来确保变异操作对于种群质量的提升。本文中采用的变异算子操作是互换变异。

首先对于后 70%的每一个染色体，随机生成[0,1]之间的一个参考参数，当这个参数的取值大于变异概率 P_m 时，对该染色体进行变异操作，即在父代染色体中随机选择两个位置进行交换，得到子染色体。再进行相应适应度计算，最高的保留到子代种群。

比如对于染色体序列[0 1 2 3 0 4 5 0]，它生成的随机数恰好大于变异概率 P_m ，则需要进行变异操作。此假设时算法中设置的变异次数为 2，则生成原始染色体序列的两个副本，并随机生成两组互换位置：(2,3)和(1,4)。则对于之前生成的副本序列进行变异操作，得到新的染色体序列为[0 1 3 2 0 4 5 0]，[0 4 2 3 0 1 5 0]。并计算二者的适应度函数值，返回

适应度函数值最大的染色体序列。具体的变异次数和优秀染色体比例需要根据问题规模进行调整。

3.2.7 算法终止条件

由于遗传算法是随机搜索算法，所以必须设置终止条件来结束该循环。常见的终止条件包含以下三类：（1）达到设定的目标适应度值（2）达到设定的时间（3）达到设定的迭代次数。在这篇文章中采用的方法是根据问题的复杂程度与规模来设置合理的迭代次数，当达到迭代次数上限时，算法将终止。

3.3 遗传算法流程图

综上所述，绘制本文中的遗传算法流程图，如图 3-1 所示

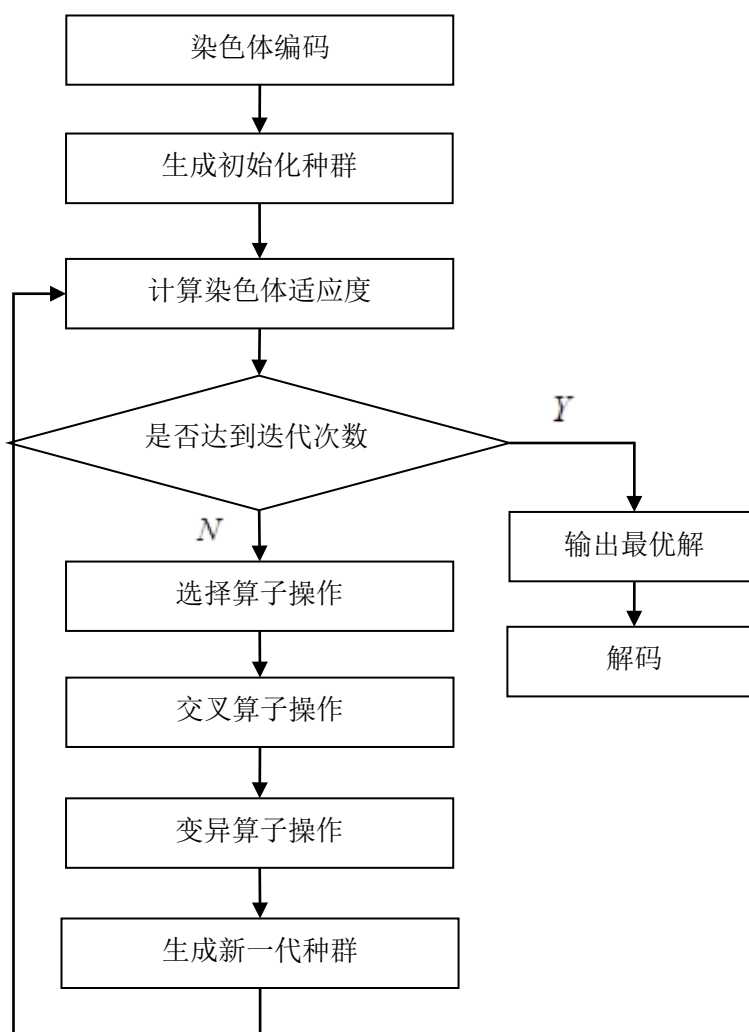


图 3-1 遗传算法流程图

3.4 本章小结

本章首先介绍了遗传算法的基本组成和优缺点，并在算法设计方面，针对传统的遗传

算法的缺陷,进行了改进和优化,使得本文的遗传算法更加适合求解含充电站和时间窗的车辆路径规划问题(E-VRPTW)。其中为了使得算法的收敛速度更快,使用载重约束来帮助初始化种群。此外,在交叉算子操作,变异算子操作中,采用了优秀染色体保护的策略,减少交叉概率和变异概率取值不当对最终结果的影响。并给出了本文设计的遗传算法的流程图以及遗传算法的伪代码。

第四章 实验结果与分析

4.1 算例介绍

在设定区域范围内，给出客户、配送中心、充电站的地理坐标信息、时间窗信息、货运量信息和服务时间信息。希望使用适当数量的电动车，并对其进行路径规划，使得整个物流配送过程的总成本最低。事实上，针对电动车物流路径规划问题，部分论文会采用 Solomon 的 VRPTW 数据集来作为参考数据集，但是根据观察，本文提出这样的做法存在一定的问题，应该构建符合自身研究问题的数据集。原因如下：

第一，大多数论文只是采用了 Solomon 的 VRPTW 数据集中 100 个数据点的前 25 个或前 30 个的数据点信息，这样的部分选择使得他们的实验结果不能使用 Solomon 的数据集所附带的标准解来验证算法的有效性。

第二，大多数论文采用的车辆模型和 Solomon 的并不相同，而且客户点时间窗上有很大的差异，所以大多数论文都是采用自己构建的时间窗和货运量等参数。这样的修改使得调用 Solomon 数据集的意义降低，只是单纯使用了部分数据点信息。Solomon 的不同数据集服从不同的分布，而这样的数据点也完全可以自主生成。

第三，Solomon 的数据集中不包含充电站的考虑，所以不论是附带的标准解还是相关的数据点，都不适合作为电动车路径规划问题的参考数据集，。

通过上述思考，本文中通过多次模拟实验，随机生成各个数据点。并且根据每辆电动车对于不同数据点平均的配送里程和耗费时间，构建了符合本文题目规模的客户时间窗，由此给出了本文实验的数据集。

4.1.1 各节点的基本信息

假设某地区有一个配送中心，需要前往同地区内的 25 个的客户处进行货物运送。每个个体都有着特定的坐标，每个客户有着相互独立的服务时间、货运量和期待的时间窗。其中序号 0 代表配送中心，序号 1~25 代表客户，序号 26、27 代表充电站。

具体每个节点的信息如表 4-1 所示。其中，充电站和货运中心的期待时间窗均为 $[0,100]$ ，这样做的目的是确保不论规划结果如何，这两类节点的宽松的时间窗都是可以包容各种情况的，也较为符合实际。

表4-1 各节点基本信息表

序号	坐标	期待的时间窗	货运量(t)	服务时间(h)
0	[50, 50]	[0, 100]	0	0
1	[10, 25]	[3, 4]	0.2	0.1
2	[58, 8]	[8, 10]	0.3	0.2
3	[97, 45]	[5, 7]	0.7	0.6
4	[88, 25]	[2, 4]	0.7	0.8
5	[18, 33]	[1, 3]	0.4	0.2
6	[21, 90]	[7, 8]	0.7	0.4
7	[32, 59]	[9, 11]	0.1	0.5
8	[63, 100]	[4, 5]	0.2	0.4
9	[41, 66]	[0, 2]	0.3	0.2
10	[120, 49]	[4, 5]	0.4	0.2
11	[73, 10]	[5, 7]	0.8	0.1

续表 4-1

序号	坐标	期待的时间窗	货运量(t)	服务时间(h)
0	[50, 50]	[0, 100]	0	0
1	[10, 25]	[3, 4]	0.2	0.1
2	[58, 8]	[8, 10]	0.3	0.2
3	[97, 45]	[5, 7]	0.7	0.6
4	[88, 25]	[2, 4]	0.7	0.8
5	[18, 33]	[1, 3]	0.4	0.2
6	[21, 90]	[7, 8]	0.7	0.4
7	[32, 59]	[9, 11]	0.1	0.5
8	[63, 100]	[4, 5]	0.2	0.4
9	[41, 66]	[0, 2]	0.3	0.2
10	[120, 49]	[4, 5]	0.4	0.2
11	[73, 10]	[5, 7]	0.8	0.1
12	[87, 99]	[2, 3]	0.1	0.6
13	[29, 30]	[0, 2]	0.5	0.5
14	[44, 31]	[10, 11]	0.2	0.3
15	[79, 60]	[7, 8]	0.4	0.1
16	[47, 25]	[10, 12]	0.4	0.3
17	[5, 56]	[10, 11]	0.5	0.3
18	[98, 15]	[4, 5]	0.3	0.2
19	[97, 87]	[3, 5]	0.9	0.7
20	[45, 99]	[5, 7]	0.1	0.4
21	[3, 10]	[3, 5]	0.7	0.5
22	[26, 71]	[7, 9]	0.4	0.4
23	[65, 83]	[0, 2]	0.6	0.1
24	[82, 41]	[1, 2]	0.8	0.3
25	[91, 76]	[4, 5]	0.6	0.5
26	[85, 55]	[0, 100]	0	0.4
27	[29, 39]	[0, 100]	0	0.4

根据上表 4-1 中各数据点的坐标分布，在下图 4-1 中绘制了所有数据点集在地图上的分布状态。其中橘色点代表配送中心，包括 0 号数据点；绿色点代表充电站，用 station 的第一个字母 s 来代表，包括 26、27 数据点；蓝色点代表客户，用 customer 的第一个字母 c 来代表，包含 1~25 数据点。

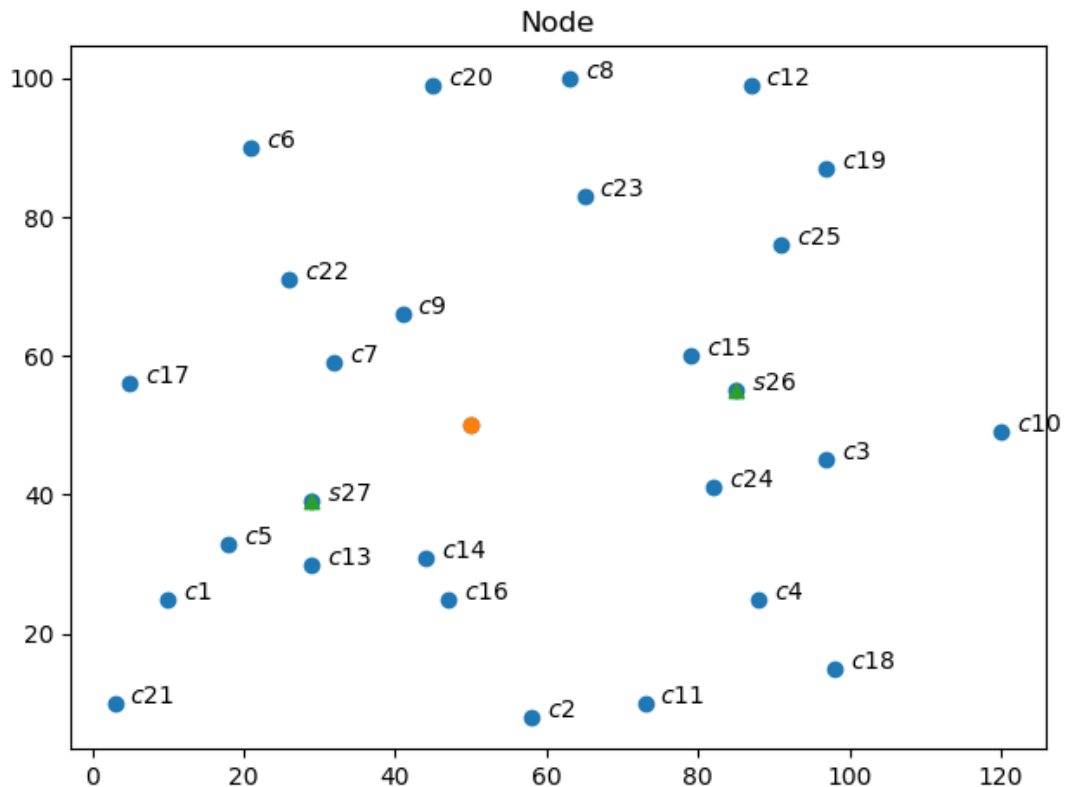


图 4-1 所有数据点在地图上的分布状态

4.1.2 电动车及其他配置的参数

针对问题规模，配送中心提供 3 辆电动车来提供服务。它们具有相同的性能，具体电动车数据参考的是北京现代 2020 款菲斯塔电动物流车^[16]，为了符合设计场景的地图规模，对于部分参数进行了同比例调整，包括电动车的续航里程、行驶速度、电池容量、运输成本等参数。具体的数据在表 4-2 中列出。根据上述条件，安排配送路线，使得整个配送的总成本最小。

表4-2 电动车及其他配置的参数设置

参数	取值
充电成本	1 元/度
运输成本	2 元/千米
载重量	5 吨
续航里程	250 千米
电池容量	50 千瓦时
行驶速度	40 千米/小时
耗电系数	0.2 千瓦时/千米

4.2 实验运行环境

本文算例是在 1.80GHZ 的 Intel(R) Core(TM) i7-8550U CPU，内存为 8GB 的 Windows10 系统计算机上运行，并通过 PyCharm 2020.1 编写并且运行代码。

4.3 算例结果与分析

对于常见的车辆路径规划问题，优化的目标是最小化车辆行驶里程和最小化车辆调用数目。因此，为了验证文中的实验参数中调用 3 辆车是合理的，即调用三辆电动车可以装

载所有的货物，本文首先通过使用精确算法中的线性规划算法来得到最优化行驶里程和车辆调用数目情况下的结果。在使用线性规划算法时，不考虑时间窗函数所带来的时间惩罚和充电站带来的充电量成本，单纯认为经过充电站 s26 或者 s27，经过该点的电动车充满电。

4.3.1 使用线性规划算法针对车辆数目选择进行验证

通过调用线性规划解法器 Cplex 的 Python API，并进行编程，设定优化的目标是最小化车辆行驶里程和最小化车辆调用数目。在这里我们不考虑时间窗于充电量，因为上述两点会带来多决策变量相乘的情况，线性规划难以求解。经过较短时间后，解法器可以求解出如图 4-2 中所示的结果。可以看到，此时，共有三段闭环路径，代表着选取 3 辆电动车确实可以所有客户点的满足货运量需求，对于遗传算法需要通过调度安排，让满足每条线路的货运量都小于车辆的载重上限的前提下，能够降低整个配送的成本，提高顾客的满意程度。

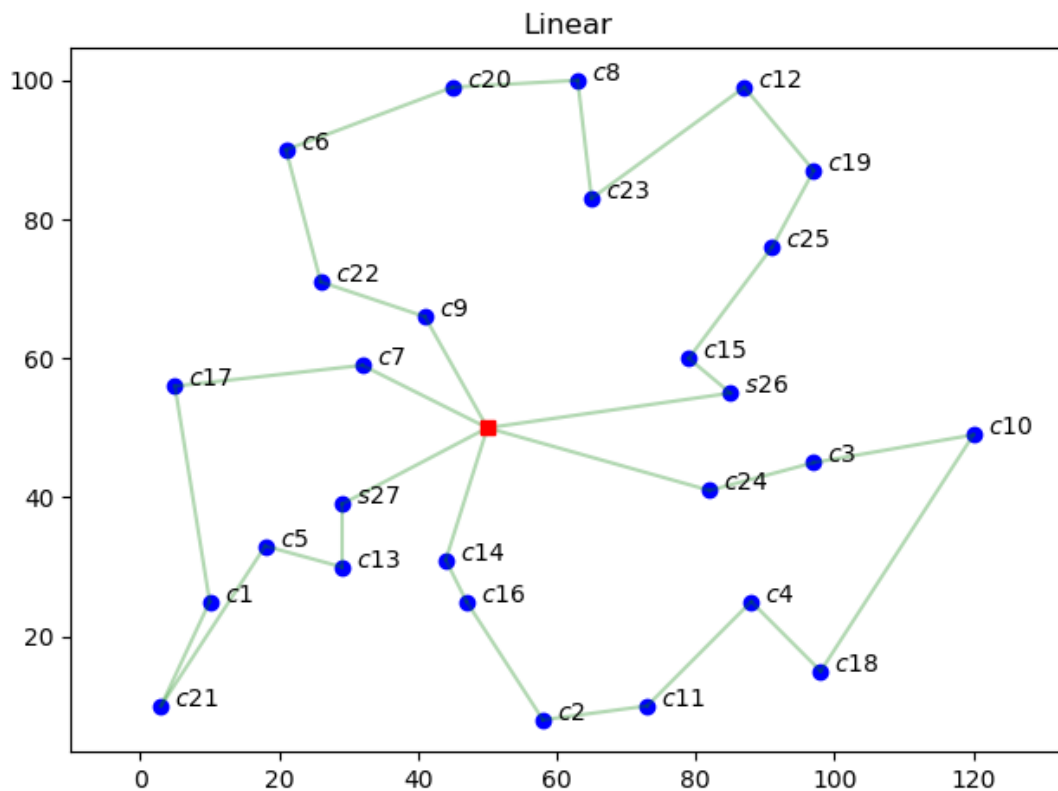


图 4-2 Cplex 的规划结果

由于优化目标之一是车辆行程最短，所以图 4-2 中的路径并不是错综复杂的，基本都是最近点之间的连线，但是，针对 E-VRPTW 问题，我们必须要考虑时间窗惩罚，充电费用等情况，为了减少因为到达时间和顾客的期待时间窗不符所带来的早到惩罚和超时惩罚，具体的车辆路线将会是很复杂的，可能会存在舍近求远的路线，来减少时间窗惩罚。

此外，先前提到线性规划方法对于存在多个决策变量相乘的情况很难给出解答，也就是说当希望考虑时间窗惩罚和充电费用时，采用单纯的线性规划算法有很大的局限性。因为根据之前模型分析中的计算公式，时间窗惩罚和充电费用这两类优化目标会存在多个决策变量相乘的问题，如果希望使用线性规划等精确算法来解决，需要使用较为复杂的数学技巧，如外逼近法(outer approximation method)等方法。

而采用遗传算法等启发式算法，可以避免这类较为复杂的数学问题，在合理的迭代次数内得到优秀的结果。因此，在通过线性规划确认 3 辆电动车的设定确实是合理的之后，本文将采用遗传算法来针对之前模型中的目标函数进行优化。

根据上述电动车参数的设定和各个数据点的时间窗、服务时长、坐标位置等设定，使用 Python3.7 对于先前模型设计中的遗传算法实现，并且设置遗传算法相关参数如表 4-3 所示。

表4-3 遗传算法的参数设置

参数	取值
种群大小	100
交叉概率	0.9
变异概率	0.1
迭代次数	5000

经过迭代后的实验结果中的路线规划图如图 4-3 所示。其中黑色路径代表车辆_0 的物流路径规划，红色路径代表车辆_1 的物流路径规划，蓝色路径代表车辆_2 的物流路径规划。

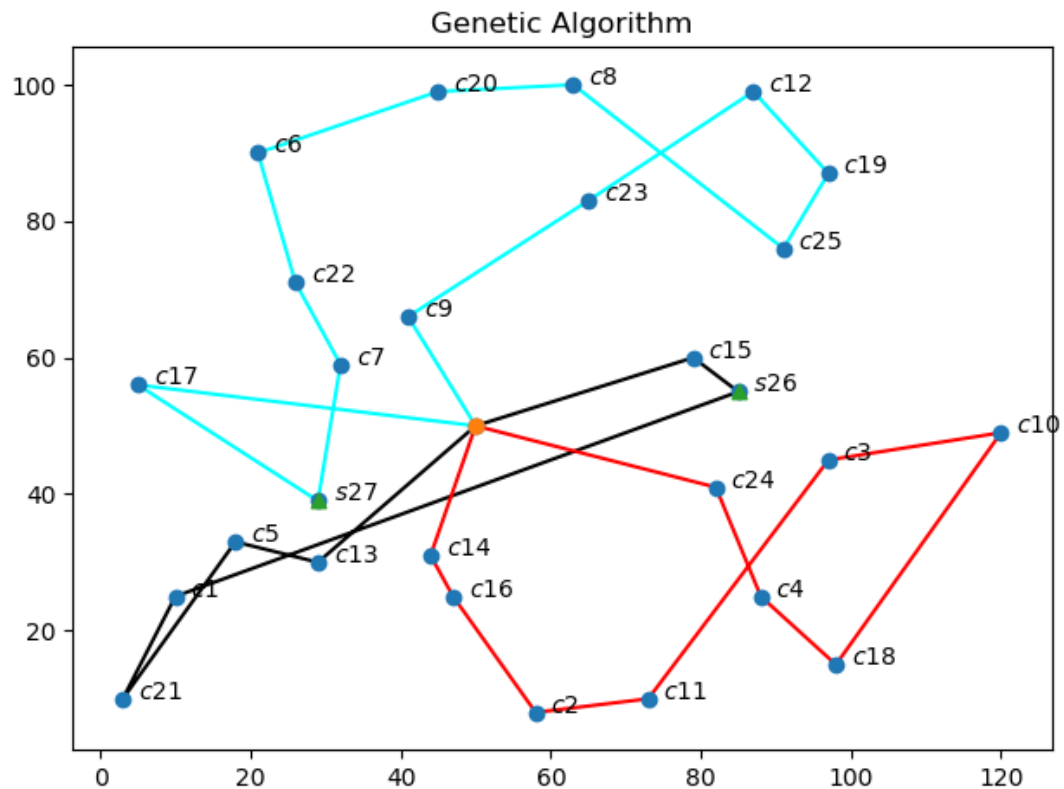


图 4-3 遗传算法的规划结果

根据实验结果，我们得出在规定迭代次数下的最优解的电动车物流路径规划，在表 4-4 中呈现：

表4-4 最优电动车物流路径规划结果

电动车辆编号	物流路径规划
车辆_0	0-13-5-21-1-26-15-0
车辆_1	0-24-4-18-10-3-11-2-16-14-0
车辆_2	0-9-23-12-19-25-8-20-6-22-7-27-17-0

对于实验输出结果中，本文关心的是如下几点：

(1) 在这样的路径规划下每个客户在什么时间点接受到了服务，和他们期待的服务时间窗相比如何？

(2) 具体每辆电动车的行驶里程是多少？

(3) 规划结果中是否存在某辆车超过载重量上限或者超过电量上限？

(4) 算法迭代的速度如何？适应度函数的收敛函数如何？

下面将针对这些点一一进行分析。

4.3.2 各个节点的时间窗的吻合情况

根据最优规划结果，输出每辆电动车的到达各个客户节点与充电站节点的时间点和具体是早到或者迟到的情况，如表 4-5 所示：

表4-5各个客户节点与充电站节点的到达时间

电动车辆 编号	节点序号	抵达时间(h)	预计时间窗(h)	早到/迟到情况
车辆_0	13	0.73	[0, 2]	准时
车辆_0	5	1.95	[1, 3]	准时
车辆_0	21	2.88	[3, 5]	早到 0.12 小时
车辆_0	1	4.10	[3, 4]	迟到 0.1 小时
车辆_0	26	4.92	[0, 100]	准时
车辆_0	15	6.05	[7, 8]	早到 0.95 小时
车辆_1	24	0.83	[1, 2]	早到 0.17 小时
车辆_1	4	1.96	[2, 4]	早到 0.04 小时
车辆_1	18	3.59	[4, 5]	早到 0.44 小时
车辆_1	10	4.62	[4, 5]	准时
车辆_1	3	5.66	[5, 7]	准时
车辆_1	11	7.09	[5, 7]	迟到 0.09 小时
车辆_1	2	8.02	[8, 10]	准时
车辆_1	16	9.05	[10, 12]	早到 0.82 小时
车辆_1	14	10.18	[10, 11]	准时
车辆_2	9	0.46	[0, 2]	准时
车辆_2	23	1.11	[0, 2]	准时
车辆_2	12	1.68	[2, 3]	早到 0.32 小时
车辆_2	19	2.74	[3, 5]	早到 0.33 小时
车辆_2	25	3.89	[4, 5]	早到 0.11 小时
车辆_2	8	4.85	[4, 5]	准时
车辆_2	20	5.71	[5, 7]	准时
车辆_2	6	6.57	[7, 8]	早到 0.43 小时
车辆_2	22	7.43	[7, 9]	准时
车辆_2	7	8.29	[9, 11]	早到 0.71 小时
车辆_2	27	9.24	[0, 100]	准时
车辆_2	17	10.11	[10, 11]	准时

我们可以看到，绝大多数的客户点都是被准时服务或者在期待的时间窗上下浮动 0.5 小时内被服务。本文中认为这样的规划结果是较为不错的，这是因为除了时间窗外，车辆行驶里程、载重量上限、电量上限都是作为物流公司应该考虑的点，在其他的这些考虑因素的权衡下，像实验结果中这样的时间窗的吻合程度在现实生活中是可以接受的。此外，本文的算例设计中，大多数客户点的时间窗的长度大小为 1 小时或者 2 小时，而通常每两

节点的路径行驶时间长度大约为 1 小时左右，因此这样的时间窗的大小其实是较为严格。

4.3.3 载重约束和电量约束的满足情况

此外，本文需要验证电动车的电量约束和载重量约束是否被满足，即路径规划结果中每辆电动车整个行程的载重量不能超过 5 吨，行驶里程不能超过 250 千米，如果经过充电站，则到达充电站前的行驶里程和离开充电站后的行驶里程不能超过 250 千米。实验结果中的行驶里程与载重情况如下表 4-6 所示。

表4-6 电动车载重情况与行驶里程情况

电动车辆 编号	物流路径规划	载重量 (t)	行驶里程(km)	超载/超 距
车辆_0	0-13-5-21-1-26-15-0	2.2	165.19&38.49	无
车辆_1	0-24-4-18-10-3-11-2-16-14-0	4.6	232.76	无
车辆_2	0-9-23-12-19-25-8-20-6-22-7- 27-17-0	4.5	236.95&74.81	无

根据上表中的实验结果，我们可以看到这样的路径规划是可行的，满足了对于本文中设定的电动车行驶里程的约束和载重量的约束要求。

根据表 4-5 和表 4-6 的结果，我们可以看到本文中采用的遗传算法，规划结果是可行的，且对于顾客的时间窗的要求有着较为优秀的处理。下一步，我们需要对于该算法的其他性能，即运行速度，迭代速度，收敛速度等进行分析。

4.3.4 算法运行速度和迭代速度的分析

不过运行速度，迭代速度，收敛速度会受到算法实现方式、采用的语言种类、计算机性能等多重因素的制约。比如使用 C++ 会比 Python 运行迅速，一台高性能计算机会比普通笔记本运行迅速，可能对于高性能计算机，迭代 500 次和迭代 5000 次的时间几乎没差别。所以下述的分析仅针对本文中的实验环境，不一定具有普适性。

首先，在实验结果中输出总共 5000 次迭代下的适应度函数和总费用随着迭代次数的变化趋势，如下图 4-4 所示。其中图 4-4 左侧显示的是电动车物流路径规划的总费用随着迭代次数的增加的变化趋势，图 4-4 右侧显示的总费用的倒数，即适应度函数 fit 随着迭代次数的增加的变化趋势。




图 4-4 5000 次迭代时适应度函数和总费用随着迭代次数的变化趋势

此外，在下表 4-7 中，详细记录了的运行结果，并分别在迭代次数为 500，1500，2000，3000，4000，5000 时记录了相应的适应度函数值，总费用以及运行时间。

表4-7 运行结果

迭代次数	适应度函数(fit)	总成本(1/fit)	运行时间
500	0.00038	2641.35	21s
1000	0.00041	2434.87	42s
1500	0.00044	2292.53	1min05s
2000	0.00044	2292.53	1min27s
3000	0.00046	2175.75	2min19s
4000	0.00046	2175.75	2min59s
5000	0.00046	2175.75	3min42s

根据图 4-4 中的变化趋势，我们可以看到，在迭代次数在 0~2000 次中的某一次后，适应度函数 fit 的值基本收敛。而当迭代次数达到 2000 次后，适应度的值基本不再发生变化，由此我们可以基本认为 5000 次迭代所得到的结果是较为优秀的，是接近这个问题最优解的一个可行解。随着迭代次数的增加，或许我们可以找到更有的路径规划安排，可是会需要大量的时间进行迭代才能得到微量的费用节省，代价和回报将会不成正比。

再让我们观察表 4-7 中记录的具体输出数值，我们可以看到迭代次数在达到 1500 次之后，增长速度放缓，且迭代次数在 3000 次到 5000 次这个区间内，适应度函数基本不再发生变化，这与我们根据图 4-4 所得出的结论基本吻合。此外，迭代次数和耗费时间基本呈线性关系，约为 500 次迭代耗时 21s。

此外，0~2000 次中的某一次后，适应度函数 fit 的值基本收敛这样的粗糙的结果并不能满足我们的需要，缺乏精确性。为了进一步看到具体迭代次数达到多少后，适应度函数的值趋向稳定，我们需要观察下图 4-5 和下图 4-6 中迭代次数为 1000 次和 2000 次时的适应

度函数值的变化曲线。




图 4-5 1000 次迭代时适应度函数和总费用随着迭代次数的变化趋势




图 4-6 2000 次迭代时适应度函数和总费用随着迭代次数的变化趋势

根据图 4-5 和图 4-6 中的结果，我们可以观察到，在迭代次数在 750 次左右时，遗传函数的适应度函数值基本达到了一个稳定的阶段。随着迭代次数的增加，适应度函数的增长量越来越小甚至几乎不变。这也与表 4-7 中的趋势吻合。

根据上述分析可知，本文设计的遗传算法在运行时间稳定性、目标函数收敛性、路径规划结果合理性、时间窗吻合程度等多方面有较为优异的表现。

但是通过实验，观察到遗传算法会较为受初始化的情况的限制，基本一个优异的初始化情况能大幅度降低达到接近最优解的可行解的时间，相反一个很差的初始化情况需要迭代很久才能达到较好的效果。本文中采用的初始化方式是根据载重约束来随机化初始的路径规划，这样的操作可以确保初始化的算子一定满足载重约束，这是目前想到并尝试过的最简单也是最有效的方案。先前有考虑用距离来贪婪匹配确定初始化子集，但以最近距离为目标的贪婪匹配，可存在的初始化子集数较少。也有考虑把柔性时间窗先变成非柔性的时间窗约束来考虑，帮助初始化子集，但是这样的设计会使得初始一次就需要进行较多的计算，可能存在的问题就是多个客户点具有相似的时间窗如何选择的问题，必须要综合考虑距离等其他因素。此外，由于充电站的英语，电量约束问题很容易解决，所以不太适合作为初始化参考因素。综上所述如果能找到一个综合考虑行驶距离，时间窗和车辆载重的初始化方式，使得初始化的种群就具有很高的适应度值，将会极大程度降低得到优秀解的迭代时间和次数，甚至对于中大规模问题能在合理时间内给出最优解。

4.4 本章小结

本章首先给出了本文的算例的设计和构思过程，之后在设计的算例进行实验验证，通过对于实验结果的分析证明了本文所设计的遗传算法在运行时间稳定性、目标函数收敛性、路径规划结果合理性、时间窗吻合程度等多方面有较为优异的表现。最后给出了从实验结果得出的改进思路。

第五章 结论

本文首先是对于带时间窗的车辆路径规划问题(VRPTW)电动车路径规划问题(E-VRP)的研究进行了介绍和分析,并给出了本文的研究内容框架和方法选择。对于含充电站和时间窗的车辆路径规划问题(E-VRPTW)的四个关键因素:配送中心,客户,电动车和充电站进行了定义。明确了目标函数为最小化车辆路径规划的总费用。总费用构成为运输成本,充电成本,时间惩罚成本,载重超量惩罚和电量耗尽惩罚。最后,给出了模型的目标函数,变量的等式关系和模型的约束条件的数学表达式。

本文对于遗传算法的实现流程和优缺点进行了分析和描述,并在算法设计方面,针对传统的遗传算法的缺陷,进行了改进和优化,使得本文的遗传算法更加适合求解含充电站和时间窗的车辆路径规划问题(E-VRPTW)。为了使得算法的收敛速度更快,使用载重约束来帮助初始化种群。此外,在交叉算子操作,变异算子操作中,采用了优秀染色体保护的策略,减少交叉概率和变异概率取值不当对最终结果的影响。

本文通过采用算例进行实验验证,证明了设计的遗传算法在运行时间稳定性、目标函数收敛性、路径规划结果合理性、时间窗吻合程度等多方面有较为优异的表现。首先,通过对于 5000 次迭代中各个迭代阶段的结果进行比较和分析,可以看到在实验环境中迭代次数和耗费时间基本呈线性关系,约为 500 次迭代耗时 21s,运行时间稳定。其次,根据不同迭代阶段的迭代结果,我们可以看到,目标函数在迭代次数到 750 次左右时,遗传函数的适应度函数值基本达到了一个稳定的阶段,随着迭代次数的增加,适应度函数的增长量越来越小甚至几乎不变,因此具有较好的目标函数收敛性。车辆路径规划结果的目标是最小化整个配送流程的总费用消耗,而我们实验结果中最终给出的规划结果满足对于电动车行驶里程的约束和载重量的约束要求。大多数客户点的时间窗的长度大小为 1 小时或者 2 小时,在本文的算例规模下,这样的时间窗长度是较为合格的,而实验结果中给出的规划结果是大多数的客户点都是被准时服务或者在期待的时间窗上下浮动 0.5 小时内被服务,时间窗吻合程度较好。

但是目前,本文对于带充电站和时间窗的车辆路径规划问题(E-VRPTW)的探索仍然是初步的,由于知识储备,研究水平和投入时间的有限,本文中存在着一定的不足和待改进的地方,下面几点可作为之后针对该问题的探索方向:

(1) 遗传算法会较为受初始化的情况的限制,一个优异的初始化情况能大幅度降低达到接近最优解的可行解的时间,相反一个很差的初始化情况需要迭代很久才能达到较好的效果。本文中着重考虑了载重约束来初始化种群,但是时间窗、电量等因素也是可以值得考虑进来的。虽然这样的做法会使得初始化种群变得复杂,但是我觉得这样的设计有机会让遗传算法更高效,更快收敛到接近最优解的情况。

(2) 遗传算法的数学性不是很强,得到的解也仅是优秀解而不是最优解。这些也是启发式算法所带来的一些问题,之后应该去考虑使用精确算法来针对这个问题进行尝试。

(3) 本文中设计的算例是较为基础的,虽然引入了客户时间窗、充电站服务、客户服务时间等因素,但实际中有更多地方值得细化。比如客户会发生时间窗变动;实际的客户之间的交通公路不可能直线的,而且会有拥堵等路况因素;充电费用和行驶费用也不可能是线性的;电动车种类也是多样的,电动车不太会全部使用单一的电动车,应该会根据不同

路线的里程距离来分配不同续航能力的电动车。

(4) 算例中设计的实验数据集并不具备验证能力，也就是说没有理论上的最优解来衡量遗传算法的结果究竟与问题的最优解有着怎样的差距，现阶段常用的 Solomon 算例也不适合我们的问题研究，所以需要进一步调研或者探索验证集的设计。

(5) 遗传算法的参数选择选择大部分是依靠经验来根据问题规模进行选择。但是这些参数，比如交叉概率和变异概率会严重影响最终结果。如果设计的参数不合理，比如变异概率过高，可能会破坏原本种群中一些优良的染色体。虽然本文中采用了部分精英保留的策略尽量保护优秀的染色体不被修改，但是参数的设计和选取应该值得更深入的研究。

参考文献

- [1] 国家能源局. 清洁能源,美丽中国新动能--我国能源结构正由煤炭为主向多元化转变[J]. 资源节约与环保, 2018, No.197(04):2.
- [2] Nalepa J, Blocho M. Adaptive memetic algorithm for minimizing distance in the vehicle routing problem with time windows[J]. Soft Computing, 2016, 20(6): 2309-2327.
- [3] Zhenfeng G, Yang L, Xiaodan J, et al. The electric vehicle routing problem with time windows using genetic algorithm[C]//2017 IEEE 2nd Advanced Information Technology, Electronic and Automation Control Conference (IAEAC). IEEE, 2017: 635-639.
- [4] Abidi H, Hassine K, Mguis F. Genetic algorithm for solving a dynamic vehicle routing problem with time windows[C]//2018 International Conference on High Performance Computing & Simulation (HPCS). IEEE, 2018: 782-788.
- [5] Marinakis Y, Marinaki M, Migdalas A. A multi-adaptive particle swarm optimization for the vehicle routing problem with time windows[J]. Information Sciences, 2019, 481: 311-329.
- [6] Zulvia F E, Kuo R J, Nugroho D Y. A many-objective gradient evolution algorithm for solving a green vehicle routing problem with time windows and time dependency for perishable products[J]. Journal of Cleaner Production, 2020, 242: 118428.
- [7] Lin J, Zhou W, Wolfson O. Electric vehicle routing problem[J]. Transportation Research Procedia, 2016, 12: 508-521.
- [8] Montoya A, Guéret C, Mendoza J E, et al. The electric vehicle routing problem with nonlinear charging function[J]. Transportation Research Part B: Methodological, 2017, 103: 87-110.
- [9] Daanish A R, Naick B K. Implementation of charging station based electric vehicle routing problem using nearest neighbour search algorithm[C]//2017 2nd IEEE International Conference on Intelligent Transportation Engineering (ICITE). IEEE, 2017: 52-56.
- [10] Zuo X, Xiao Y, Zhu C, et al. A Linear MIP Model for the Electric Vehicle Routing Problem with Time Windows Considering Linear Charging[C]//2018 Annual Reliability and Maintainability Symposium (RAMS). IEEE, 2018: 1-5.
- [11] Erdelić T, Carić T. A survey on the electric vehicle routing problem: variants and solution approaches[J]. Journal of Advanced Transportation, 2019, 2019.
- [12] Zhou Y, Chen L, Yang Y, et al. Electric vehicle routing problem: Model and algorithm[C]//2020 12th International Conference on Measuring Technology and Mechatronics Automation (ICMTMA). IEEE, 2020: 1049-1054.
- [13] Basso R, Kulcsár B, Sanchez-Diaz I. Electric vehicle routing problem with machine learning for energy prediction[J]. Transportation Research Part B: Methodological, 2021, 145: 24-55.
- [14] 邱平. 车辆路径问题研究[D]. 大连海事大学, 2007.
- [15] 张璨辉, 陈向群, 谈晓妍,等. 基于遗传算法的电力设备配送优化研究[J]. 仪器仪表用户, 2016(23):68-70
- [16] 北京现代 2020 款菲斯塔电动物流参数配置 [EB/OL].(2020)[2021-05-10].
<https://car.autohome.com.cn/config/series/5370.html>
- [17] 汪丽颖. 电动车充电站策略与运输路径优化问题研究[D]. 上海交通大学, 2016.
- [18] Moghaddam N M . The partially rechargeable electric vehicle routing problem with time windows and capacitated charging stations[J]. Dissertations & Theses - Gradworks, 2015.

- [19] 杨沈宇. 基于电动车的物流配送低碳路径优化问题[D]. 浙江工商大学, 2017.
- [20] 张雁翔, 祁育仙. 改进遗传模拟退火算法求解 TSP[J]. 智能计算机与应用, 2017(3).
- [21] Dominik, Goeke, Andreas, et al. The electric vehicle-routing problem with time windows and recharging stations[J]. Operations Research Management Science, 2015.

谢辞

时间真快呀，爸爸妈妈是这样感慨的，我也经常这么想。爸爸常说前两天我这面还在跟别人吹我儿子在交大读书，咋转眼小王就要毕业了。我听到后，心中也常常会感到很落寞。是呀，搬进宿舍的第一天发生的事我今天仍记得很清楚，似乎就在眼前，咋就这么快啊，我怎么就要毕业了。仔细想来，大学这些年，也是经历了很多事情，遇到很多人，提到感谢，自己真的是感觉有很多话想说。

首先，我非常感谢张弘毅同学。弘毅同学是我大学四年来最好的朋友，不论是我学业上遇还是生活上，弘毅同学都给了我无数的关心和支持。有的时候我真的会想，如果我的大学生涯中没有弘毅，那将会是怎样的呢？那么多的坎坷，谁会给我伸出援手呢？身边发生了那么多事情，有趣的事、奇怪的事，我又该向谁倾诉呢？有一个可以说真心话，真心对待你的朋友，真的是件很幸运的事情，我很开心也很庆幸，大学里有弘毅这样的好朋友。弘毅真的是一个优秀的人，很谦逊也很努力，祝愿弘毅在交大的博士生涯万事胜意！也希望我们友谊长存！

此外，非常感谢我的家人，我的爸爸妈妈，我的姥姥姥爷。从小到大，我几乎都没有离开你们身边，从幼儿园到小学再到高中再到大学，我几乎没离开过上海，不像很多外地来的同学，已经有些背井离乡的意味了，我还未曾体验过孤身一人，远在他乡的感觉。有时，我也很纳闷，为什么我的室友他们也不给家里打电话，放假了也不愿意回家，不过仔细想想，刚上大学时我不也是这样吗？刚上大学那两年，我回家的次数很少，倒不是没空回家，只是自己没那么愿意回家了，感觉麻烦，大多都是爸爸妈妈开车来见我，或是送些衣服、吃的给我，或是一起聚个餐。我那时也不是很理解，因为那个时候我的心里更多只是自己，我没有把陪伴家人这件事想得太重，因为那时我不曾失去重要的人，也不明白这样的亲情到底有多珍贵。以前回家，姥姥总是劝我，劝我别太拼。那时我口头上总是说知道啦知道啦，其实心里是不认同的，我觉得有很多事情姥姥不明白。直到姥姥走了，很突然，就在我眼前，就是一眨眼的事情，我以为姥姥只是一时难受，并没有大碍，因为我从来不曾设想真的会有这么一天的到来，我以为这件事很远很远。这件事情之后，我才意识到亲人的离开真的只是一刹那的事情，不论自己再怎么努力，再怎么成功，亲人如果失去了，永远也不会再回来。所以能做的只是珍惜当下，珍惜眼前人。之前自己一直想着要出国，要在国外挣钱，想象着自己以后的生活，想着自己成为高层，想着自己去成功创业。那个时候心里更多只是自己，但我现在没有那么多想法了，我可能不想太拼了，也可能只是为自己找借口，生活再忙，我也希望自己能有所取舍。从小到大，在奔波的过程中我们放下了太多的快乐，之后的生活是不是也该考虑适当放下些呢？我没有什么远大的抱负，我没有想着学成归来报效祖国的那种格局，可能只是在国外工作一段时间，回来找一个自己喜欢的，宽松点的工作，少挣些也无所谓吧。我只是想多陪陪爸妈，多点时间呆在一起，做做饭，旅旅游，也会很开心吧。好害怕有一天，爸爸妈妈生病了，我在外面回不来，那我该多难过啊。谢谢爸爸妈妈，姥姥姥爷这 20 年来的恩情，我一定是无法报答的，我只希望可以尽可能多陪陪你们，少留些遗憾，少些愧疚。

最后，非常感谢尚策老师在毕业设计对我的指导和帮助。在毕设的过程中，尚老师给了我很多宝贵的建议，特别在算法的设计上，尚老师提出了遗传算法的一些缺陷，建议

让我尝试数学性较强的精确算法。通过和尚老师的沟通，我意识到之前看的文献过于片面，很多文章的一些观点也是错误的。在认识到这问题后，我不仅尝试了数学公式的变换与参量定义的改变，也尝试了使用线性规划求解器来解决问题。虽然最终自己没能做出和遗传算法相当的成果，但是在尝试的过程中我阅读了许多高质量的新文献，从这些文献中我了解了更多，以更宽广的角度对于这个问题进行了思考，特别是对数学模型的构成有了更深入的认识。衷心希望尚策老师在之后的工作和生活中都能一帆风顺！此外，也非常感谢其他在大学生涯中帮助过我的老师和同学们。不论是科研上，还是生活上或是学业上，我都曾遇到过很多困难，但也遇到很多可爱的人给我提供帮助，写到这里，现在脑海中我能立马浮现出很多人的身影。想到你们，我真的会很开心，也会很庆幸，很高兴遇见你们，谢谢你们！

离别似乎总是在盛夏，希望大家都能一帆风顺，前程似锦！

JOINT OPTIMIZATION OF ELECTRIC VEHICLE DELIVERY AND CHARGING

This article first introduces and analyzes the research on the Vehicle Routing Problem with Time Window (VRPTW) and Electric Vehicle Path Routing Problem (E-VRP), and gives the research content framework and method selection of this article. Four key factors of the Vehicle Routing Problem with Time Window and Charging Station (E-VRPTW) are defined: distribution center, customer, electric vehicle and charging station. It is clear that the objective function is to minimize the total cost of vehicle path planning. The total cost is composed of transportation cost, charging cost, time penalty cost, overload penalty and power exhaust penalty. Finally, the objective function of the model, the equation relationship of the variables and the mathematical expressions of the constraint conditions of the model are given.

In this paper, an example is used for experimental verification, which proves that the designed genetic algorithm has an excellent performance in many aspects such as stability of running time, the convergence of objective function, the reasonableness of path planning results, and degree of time window coincidence. First of all, by comparing and analyzing the results of each iteration stage in 5000 iterations, it can be seen that the number of iterations and the time spent in the experimental environment are basically linear. It takes about 21s for 500 iterations, and the running time is stable. Secondly, according to the iteration results of different iteration stages, we can see that when the number of iterations of the objective function reaches about 750, the fitness function value of the genetic function basically reaches a stable stage. As the number of iterations increases, the fitness function value The growth of the function is getting smaller and smaller or even almost unchanged, so it has better convergence of the objective function. The goal of the vehicle path planning results is to minimize the total cost of the entire distribution process, and the planning results finally given in our experimental results meet the constraints on the mileage of electric vehicles and the constraints on the load. The length of the time window for most customer points is 1 hour or 2 hours. Under the scale of this paper, such a time window length is more qualified, and the planning results given in the experimental results are most customer points They are all served on time or within 0.5 hours of fluctuations in the expected time window, and the time windows are in good agreement.

However, the exploration of the Vehicle Routing Problem with Time Window and Charging Station (E-VRPTW) in this article is still preliminary. Due to the limited knowledge reserve, research level and investment time, there are certain deficiencies and needs to be improved in this article. Where, the following points can be used as the direction of exploration for this problem in the future:

The genetic algorithm is more limited by the initialization situation. An excellent initialization situation can greatly reduce the time to reach a feasible solution close to the optimal solution. On the contrary, a very poor initialization situation requires a long iteration to achieve a

better solution. effect. This article focuses on the load constraint to initialize the population, but factors such as time window and power are also worth considering. Although this approach will complicate the initial population, I think this design has the opportunity to make the genetic algorithm more efficient and converge to a situation close to the optimal solution faster.

The mathematics of genetic algorithm is not very strong, and the solution obtained is only an excellent solution rather than an optimal solution. These are also some of the problems brought by the heuristic algorithm, and then you should consider using an accurate algorithm to try to solve this problem.

The example designed in this article is relatively basic. Although the customer time window, charging station service, customer service time and other factors are introduced, there are more points worthy of refinement in practice. For example, customers will have time window changes; actual roads between customers cannot be straight, and there will be road conditions such as congestion; charging fees and driving costs cannot be linear; electric vehicles are also diverse, electric vehicles It is unlikely that a single electric vehicle will be used for all, and electric vehicles with different endurance capabilities should be allocated according to the mileage distance of different routes.

The experimental data set designed in the calculation example does not have the ability to verify, that is to say there is no theoretical optimal solution to measure the difference between the result of the genetic algorithm and the optimal solution of the problem. At this stage, the commonly used Solomon example is not suitable for our problem research, so further investigation or exploration of the design of the verification set is needed.

The parameter selection of genetic algorithm is mostly based on experience to choose according to the scale of the problem. But these parameters, such as crossover probability and mutation probability, will seriously affect the final result. If the designed parameters are unreasonable, such as the probability of mutation is too high, some good chromosomes in the original population may be destroyed. Although the strategy of partial elite retention is adopted in this article to protect the excellent chromosomes from modification as much as possible, the design and selection of parameters should be worthy of more in-depth research.